

• 论 著 •

# 基于三重注意力机制与空间分层池化策略的膝外翻步态识别模型设计与应用研究

宋校能<sup>1</sup>, 钱琨<sup>2</sup>, 后烜<sup>3</sup>, 王亦哲<sup>4</sup>

1. 江南大学 体育部 (江苏无锡 214122)

2. 江南大学 人工智能与计算机学院 (江苏无锡 214122)

3. 澳门科技大学 创新工程学院 (澳门 0999078)

4. 香港中文大学 (深圳) 理工学院 (广东深圳 518172)

**【摘要】** 为实现儿童膝外翻的早期智能筛查, 本文设计并构建了一种融合深度学习机制的步态识别模型。该模型基于三维残差网络架构, 集成三重注意力模块与空间分层池化模块, 有效强化时域、空域与通道维度的信息交互能力, 且兼顾特征提取效果与计算效率。模型在自建数据集训练、验证和测试, 其精确率分别为 98.0%、97.1% 和 96.5%, 召回率分别为 97.5%、97.0% 和 95.0%,  $F_1$  分数分别为 0.98、0.97 和 0.96, 展现出优异的识别性能与良好的泛化能力。通过消融实验验证了本文构建模型的关键组件对性能提升的重要性, 对比实验进一步突显了其在识别精度与鲁棒性方面的显著优势, 以及通过可视化实验发现本文模型能有效聚焦于步态图像中的关键区域, 其关注区域与临床解剖标志相吻合, 提升了模型决策在临床应用中的可解释性。综上所述, 本文所提出的模型不仅为儿童膝外翻的早期智能筛查提供了高效可靠的技术手段, 也为步态识别技术在医学诊断中的应用提供了切实可行的实践路径。

**【关键词】** 膝外翻; 步态识别; 三重注意力模块; 空间分层池化模块

## The design and application of a genu valgum gait recognition model based on triple attention mechanism and spatial hierarchical pooling strategy

SONG Xiaoneng<sup>1</sup>, QIAN Kun<sup>2</sup>, HOU Xuan<sup>3</sup>, WANG Yizhe<sup>4</sup>

1. Department of Physical Education, Jiangnan University, Wuxi, Jiangsu 214122, P. R. China

2. School of Artificial Intelligence and Computer Science, Jiangnan University, Wuxi, Jiangsu 214122, P. R. China

3. School of Innovation Engineering, Macau University of Science and Technology, Macau SAR 0999078, P. R. China

4. School of Science and Engineering, The Chinese University of Hong Kong, Shenzhen, Guangdong 518172, P. R. China

Corresponding author: QIAN Kun, Email: kqian@jiangnan.edu.cn

**【Abstract】** To facilitate the early intelligent screening of pediatric genu valgum, this study develops a deep learning-based gait recognition model tailored for clinical application. The model is constructed upon a three-dimensional residual network architecture and incorporates a triplet attention module alongside a spatial hierarchical pooling module, jointly enhancing feature interaction across temporal, spatial, and channel dimensions. This design ensures an optimal balance between representational capacity and computational efficiency. Evaluated on a self-constructed dataset, the model achieves precision of 98.0%, 97.1%, and 96.5%, recall rates of 97.5%, 97.0%, and 95.0%, and  $F_1$ -scores of 0.98, 0.97, and 0.96 on the training, validation, and test sets, respectively, demonstrating excellent recognition performance and strong generalization ability. Ablation experiments confirm the importance of the proposed model's core components in improving performance, and comparative experiments further highlight its significant advantages in recognition accuracy and robustness. Visualization experiments reveal that the model effectively focuses on key regions of gait images, with attention regions aligning closely with clinical anatomical landmarks, thereby enhancing the interpretability of the model's decision-making in clinical applications. In summary, the proposed model not only offers an efficient and reliable technical solution for early intelligent screening of genu valgum in children, but also provides a

DOI: 10.7507/1001-5515.202504005

基金项目: 教育部人文社会科学研究项目 (24YJA890031)

通信作者: 钱琨, 邮箱: kqian@jiangnan.edu.cn



practical pathway for applying gait recognition technology in medical diagnosis.

【Key words】 Genu valgum; Gait recognition; Triple attention module; Spatial hierarchical pooling module

## 0 引言

儿童健康与发展是联合国和世界卫生组织重点关注的领域<sup>[1]</sup>。《中国儿童发展纲要(2021—2023年)》明确提出,要加强儿童健康管理与服务,推动健康关口前移,实施早诊断、早治疗和早康复的健康政策<sup>[2]</sup>。在此背景下,影响儿童身心发展的体态健康管理,逐渐受到广泛关注<sup>[3]</sup>。

在儿童体态健康管理中,早期预防和干预下肢异常腿型尤为重要<sup>[4]</sup>。研究表明,0~8岁儿童的下肢腿型发育遵循特定的生理演变模式:婴儿期下肢通常表现为膝内翻,约1.5岁时下肢趋于直立,在3~4岁时下肢逐渐转变为膝外翻,至7~8岁腿型逐步接近成人特征<sup>[5-7]</sup>。尽管在这一演变过程中大多数儿童的腿型会自行矫正,但仍有部分儿童腿型成人化后持续异常<sup>[8]</sup>。Jamil等<sup>[7]</sup>研究表明,对于儿童的膝内外翻问题,应根据不同程度采取必要的矫正治疗,如膝外翻超过10 cm或膝内翻超过5 cm时,即应考虑予以矫正治疗。流行病学调查显示,约有7.1%的学龄儿童(5~13岁)体态呈重度膝外翻,需要施以外科治疗干预;有20%的儿童无法通过自身生长发育纠正下肢力线的异常排列;上述过高的比例与儿童时期异常腿型未能及时矫正密切相关<sup>[9]</sup>,最终有可能发展为永久性畸形,而这些畸形问题在成熟步态模式形成之前即可初见端倪。Di Gennaro等<sup>[10]</sup>研究表明,对于膝内外翻下肢力线排列发展超出正常范围的发育期儿童,早期的评估及干预极为重要。若未及时干预,其异常腿型会导致关节应力分布异常,进而增加肌肉失衡与慢性疾病的发生风险,导致下肢发育畸形,最终影响儿童的运动能力及体态健康<sup>[11]</sup>。已有研究表明,膝外翻会使股骨传递的压力和摩擦力集中于膝关节的一侧,进而破坏下肢肌群的发展平衡,尤其是非对称性的膝内外翻腿型<sup>[12-13]</sup>,不仅增加了膝关节内外侧副韧带和前交叉韧带损伤的风险,还可能导致内外侧软骨的磨损,最终引发膝关节骨性关节炎。

在儿童下肢的畸形发生率中,膝外翻居第二位<sup>[14]</sup>。儿童时期是矫正生理性膝外翻的关键期,在6~7岁步态成人化的过渡时期进行干预,可取得事半功倍的效果<sup>[7, 15]</sup>。然而,一旦错过这一时期,不仅矫正难度大、效果差,而且成功率较低。

在预防和矫正儿童膝外翻腿型的临床医学研

究中,首要环节是识别和诊断膝外翻腿型。及早地发现,及时地矫正膝外翻,不仅有助于降低膝外翻由功能性异常发展为结构性异常的风险,还有助于发现与病理性膝外翻腿型步态表征相关的疾病,如脊髓灰质炎、佝偻病、神经肌肉系统疾病等病理性膝外翻畸形,以及由肿瘤和感染等因素导致的病理性膝外翻畸形<sup>[16]</sup>。

传统的儿童膝外翻腿型识别主要依赖专业医务人员的手工测量和医学影像诊断<sup>[17-18]</sup>,该方法不仅耗时耗力,且识别结果易受主观判断和专业水平影响。此外,传统识别手段多聚焦于静态结构评估,难以有效量化步态过程中的动态特征,限制了早期与精准识别的实际应用。

近年来,人工智能与计算机视觉技术的融合推动了步态识别的快速发展。以卷积神经网络(convolutional neural network, CNN)为代表的深度学习模型在该领域取得突破,识别精确率(precision, Pre)高达90%<sup>[19-20]</sup>,且广泛应用于帕金森病等神经退行性疾病的辅助诊断与下肢康复评估<sup>[21-22]</sup>。在膝外翻运动障碍检测中,深度学习不仅提升了特征提取精度,还具备预测步态演变趋势的潜力,为个体化干预提供技术支持<sup>[23]</sup>。

在此基础上,注意力机制作为关键扩展模块被引入,强化了模型对时空特征的分类。研究显示,空间、通道和时间注意力在特征增强中各具优势,其协同建模显著提升对关键特征的识别效果<sup>[24-25]</sup>。多维注意力机制,如三重注意力模块(triplet attention module, TAM),在图像分类、视频识别及步态识别任务中表现出良好的性能<sup>[26-28]</sup>。部分研究亦将其与时序建模相结合,围绕下肢角度和运动轨迹等关键参数实现高效识别<sup>[29-31]</sup>。

尽管多维注意力机制在图像分类、视频识别及步态识别任务中取得显著进展,但是相关模型在实际应用中仍面临四个方面的挑战:①动态建模能力有限,缺乏对肌骨系统协同运动的整体表征<sup>[32]</sup>;②解剖先验缺失,难以精准定位膝内收角等关键结构<sup>[33]</sup>;③计算开销较高,大型模型不适用于资源受限场景<sup>[34]</sup>;④模型可解释性不足,影响临床信任与推广<sup>[35]</sup>。

为有效应对上述挑战,本研究设计了一种基于结构化标注的视频步态识别模型,力图在建模能力、结构感知、计算效率及可解释性等方面实现系统性突破。其创新点为:①采用结构化标注策

略：融合视频与内踝/踝间距测量，构建标注数据集；② 构建 TAM：融合时间、空间与语义通道，强化关键特征感知；③ 应用空间分层池化模块（spatial hierarchical pooling module, SHPM）：通过多尺度区域划分与层级聚合机制，在保留全局结构信息的同时强化局部细节表达，实现多尺度特征提取与计算效率之间的有效平衡；④ 引入梯度加权类激活映射（gradient-weighted class activation mapping, Grad-CAM）进行特征可视化，揭示模型关注区域与下肢解剖结构之间的对应关系，从而增强模型决策的临床可解释性。

本研究旨在构建适用于儿童膝外翻早期筛查的高效、可解释步态识别系统，为体态健康评估的智能化与临床转化提供理论依据与技术路径。

1 研究对象及概念界定

1.1 研究对象

本文研究对象为无锡市保利实验幼儿园和滨湖幼儿园的 860 名学龄前儿童，研究全程通过江南大学医学伦理委员会的审核批准（批准编号：JNU2023099011RB04），主要内容如下：本研究采集学龄前儿童的步态信息包括：测量膝距和踝距，录制单人行走视频，录制视频的摄像机镜头正对拍摄对象。每个录制视频段的长度为 15~20 s，涵盖了被拍摄对象往返行走 20 m 的过程。数据采集后进行数据分析和编码，用于下一步的机器步态识别和深度学习，采用运动的手段对异常步态儿童进行矫正。所有受试者的监护人均签署了知情同意书，自愿参与测试，并同意本文作者在严格保密前提下使用相关信息。受试者的基本信息如表 1 所示，其中本研究共选取 240 名受试者的单人行走步态视频数据，具体包括：120 段膝外翻腿型视频以及 120 段正常腿型视频。

1.2 腿型及步态概念界定

依据医学诊断标准，在人体自然站立状态下，若双侧内踝和内踝均能自然贴合，则为正常腿型；若双膝内侧踝自然靠拢时，双内踝之间存在可测距离（大于 0），则为膝外翻腿型<sup>[36]</sup>。同时，根据测量数据所对应的视频信息，将模型识别步态特征定义为正常腿型与膝外翻腿型的行走姿态，即正常步态与膝外翻步态，如图 1 所示。

2 步态识别模型构建与实现

2.1 步态数据集构建与预处理

2.1.1 数据采集策略 本研究共采集 860 名学龄前



正常步态                      膝外翻步态

图 1 步态人工分类

Fig.1 Manually annotated gait classification

表 1 受试者的基本信息

Tab.1 The basic information of the participants

| 腿型类别     | 受试者数量/名 |         |
|----------|---------|---------|
|          | 男/女     | 5岁/6岁   |
| 总受试者     | 426/434 | 398/462 |
| 选取的正常腿型  | 60/60   | 60/60   |
| 选取的膝外翻腿型 | 52/68   | 72/48   |

儿童的腿型与步态数据，具体包括：① 腿型测量数据：通过测量双下肢内踝与踝间距，获取正常与膝外翻个体的下肢结构指标，用于腿型分类标注。

② 步态视频数据：使用高清摄像设备拍摄受试者在标准通道中单人往返行走 20 m 的步态视频，拍摄时长约为 15~20 s，确保覆盖完整的步态周期，便于后续步态特征提取与模型训练。

2.1.2 数据处理方法 为提升模型训练效率并确保步态特征的时空一致性，本研究对原始视频数据进行标准化处理，具体步骤如下：第一步，帧抽取与图像序列生成：根据设定的帧率参数，将原始步态视频划分为连续的静态图像帧序列，以保留和凸显步态的时序特征。第二步，中心裁剪：对每帧原始分辨率为 2 560 × 1 440 的图像进行中心区域裁剪，提取 224 × 224 像素的图像块，用于标准化输入。第三步，剪辑包构建：采用滑动窗口机制将连续图像帧组合为剪辑包，每个包包含 16 帧连续图像，用于后续模型的时序建模与特征学习。第四步，批量划分：结合计算硬件资源与任务需求，将输入数据划分批次，每个批次包含 16 个样本，以提升训练效率并稳定模型收敛过程。

2.1.3 样本均衡与增强措施 为缓解模型在训练过程中对类别样本的过拟合问题，通过随机旋转、镜像、裁剪等图像增强方式扩展膝外翻的样本多样性，以提升模型对轻度、边缘类膝外翻步态的识别






图2 步态识别模型整体结构与工作流程

Fig.2 Overall architecture and workflow of the gait recognition model

鲁棒性。具体操作为：① 随机旋转：在 $\pm 10^\circ$ 的范围内进行随机旋转，模拟不同拍摄角度下的步态变化，使模型能够适应不同视角下的步态特征。② 水平翻转：以 50% 的概率对图像进行镜像处理，增强模型对左右腿对称性变化的学习能力，提升模型的泛化性能。③ 随机裁剪与缩放：随机裁剪图像局部区域并缩放至标准尺寸，使模型能够更好地学习局部特征，增强模型对图像位置变化的适应能力。④ 亮度与对比度扰动：在图像上引入亮度和对比度的随机扰动，模拟不同光照条件下的图像变化，提升模型在不同拍摄环境下的适应能力。

**2.1.4 数据样本抽样与标签分配** 在对 860 名学龄前儿童的步态视频进行筛选后，剔除其中 15 段因画面质量欠佳或下肢运动轨迹不清晰而无法准确判定腿型的视频，之后选取 240 段单人行走步态视频数据。具体包括：120 段膝外翻腿型视频和 120 段正常腿型视频，详细信息如表 1 所示。该数据集在类别分布上的平衡设计，有效避免了模型训练过程中因类别不均衡而产生的偏倚，为后续的分类建模与性能评估提供了可靠的数据基础。

步态视频的标注由两位临床医学博士（分别为教授与副教授）和一位体育教育训练学博士（副教授）共同完成。研究团队依据每位受试者的腿型测量数据并对应其步态视频，进行特征标注。完成标注后，数据集按照正常步态和膝外翻步态 1:1 的比例分别划分为训练集（64%，154 名）、验证集（16%，38 名）和测试集（20%，48 名），用于后续模型训练与性能评估<sup>[37]</sup>。

## 2.2 步态识别模型架构设计

为提升模型对步态数据的拟合能力及其对关

键特征的聚焦能力，增强识别的准确性与泛化性能，本文设计了一种融合时间卷积、空间卷积、通道等注意力机制与多尺度特征融合策略的步态识别模型，其整体结构与工作流程，如图 2 所示。

**2.2.1 TAM 设计与融合原理** 为增强模型对步态时空特征的判别能力，本研究设计了 TAM，该模块通过时间注意力、空间注意力和通道注意力的协同作用，从多维度对步态特征进行加权建模，突出关键时间帧、关键身体部位及高语义通道。TAM 的结构如图 3 所示，具体包括四个部分：第一部分，时间注意力用于学习步态周期中各时间帧的动态特征，增强模型对时序变化的敏感性。其具体流程为：① 输入嵌入与位置编码：原始步态序列通过输入嵌入层——三维卷积层（three dimensional convolution, Conv3D）转换为时空特征。加入时间位置编码，保留步态运动的时序顺序信息。② 时空特征提取：使用 Conv3D 提取局部时空特征（如相邻帧的步态动态）。③ 时间维度加权：展平时间维度，将特征图的时间轴展开为序列形式，便于全局注意力计算。④ 柔性最大值（softmax）加权：通过自注意力机制生成时间步权重，归一化后对关键帧（如步态周期中的支撑相或摆动相）进行增强。⑤ 还原时间维度：将加权后的特征重新折叠为原始时间维度，输出时序增强特征。时间注意力机制的关键点在于通过时间位置编码和柔性最大值加权，模型能够区分步态周期中的阶段性变化（如起步、迈步、落地）。第二部分，空间注意力聚焦步态图像中的关键身体部位，抑制背景噪声干扰，提升特征提取的判别性。其具体流程为：① 空间位置编码：在特征图中嵌入空间位置编码，标记各身体




图3 TAM 结构

Fig.3 Structure of the TAM

部位的空间位置关系。② 空间平均池化：沿高度和宽度维度池化，生成空间全局描述向量。③ 注意力权重生成：通过全连接层结合柔性最大值计算空间注意力分布，突出关键区域（如摆动腿的轨迹区域）。④ 维度扩展：将一维权重映射回原始空间维度 [高度 ( $H$ ) × 宽度 ( $W$ ) ]，与输入特征逐点相乘，输出空间增强特征。空间注意力机制的关键点在于结合位置编码和空间池化，模型能自适应捕捉局部肢体运动模式（如步幅、关节角度）。第三部分，通道注意力模块通过动态调整特征通道的权重，突出与步态语义高度相关的通道信息，进一步增强模型对关键特征的代表能力。其具体流程为：① 通道描述生成：空间平均池化，沿时空维度 [时间维度 ( $T$ ) × 高度 ( $H$ ) × 宽度 ( $W$ ) ] 压缩，生成通道统计向量。② 通道相关性建模：通过“全连接层—修正线性单元—全连接层”结构学习通道间非线性关系。③ S 型生长曲线 (sigmoid) 激活：生成 0~1 的通道权重，抑制冗余通道，增强判别性通道（如表征步态周期的低频通道）。④ 通道加权：将权重与原始特征逐通道相乘，输出通道增强特征。通道注意力机制的关键点在于通过通道间

的交互建模，模型能自动选择与步态身份相关的高语义特征。第四部分，TAM 的融合机制整合时间、空间与通道注意力特征，构建多维度判别性表示，进一步提升模型对复杂步态特征的感知与判别能力。其融合策略为：① 加权融合：对三类注意力特征进行可学习加权，如式 (1) 所示：

$$F_i = \alpha F_1 + \beta F_2 + \gamma F_3 \quad (1)$$

其中， $F_i$  为最终融合得到的特征图； $F_1$ 、 $F_2$ 、 $F_3$  分别表示由时间注意力、空间注意力和通道注意力提取得到的特征图； $\alpha$ 、 $\beta$ 、 $\gamma$  为动态调整的融合系数，用于控制三类注意力特征的重要性，满足约束条件  $\alpha + \beta + \gamma = 1$ 。② 层级互补性：时间注意力聚焦步态周期，空间注意力捕捉肢体局部运动，通道注意力优化特征表达，三者互补增强模型判别力。③ 最终输出多维注意力特征，用于后续步态识别任务。

**2.2.2 SHPM 结构与计算机制** 本文模型引入了改进结构——SHPM，该模块兼具空间金字塔池化 (spatial pyramid pooling, SPP) 的优点与更高的结构灵活性，旨在增强模型对图像和视频复杂空间

结构的多尺度特征提取能力<sup>[38]</sup>。SHPM 在每个子区域中分别执行平均池化与最大池化操作，其计算公式如式 (2) 和式 (3) 所示：

$$\eta_{b,c,i,j} = \frac{1}{(H_{size} \times W_{size})} \sum_{h=0}^{H_{size}-1} \sum_{w=0}^{W_{size}-1} X_{b,c,i,j,h,w} \quad (2)$$

$$\mu_{b,c,i,j} = \max_{h=0}^{H_{size}-1} \max_{w=0}^{W_{size}-1} X_{b,c,i,j,h,w} \quad (3)$$

其中， $\eta_{b,c,i,j}$  表示对第  $b$  个样本在通道  $c$ 、时间段  $i$ 、空间区块  $j$  中，所有像素位置的特征响应值； $X_{b,c,i,j,h,w}$  为进行平均池化所获得的结果； $\mu_{b,c,i,j}$  表示对相同区域执行最大池化所得的特征响应。变量  $h$  与  $w$  分别为该空间子块内的行与列位置索引， $H_{size}$  与  $W_{size}$  分别为该区块的高度与宽度。

SHPM 将每个区间的平均值和最大值拼接在一起，得到最终的输出张量  $\mathbf{Y} \in \mathbf{R}^{B \times C \times T \times H_{bins} \times (2W_{bins})}$ ；其中， $\mathbf{Y}$  为融合后的五维特征张量； $B$  为批量大小， $C$  为通道数， $T$  为时间维度帧数； $H_{bins}$  为水平区域划分数， $W_{bins}$  为垂直区域划分数；系数 2 表示每个区域拼接了最大池化与平均池化两种特征。

为实现信息保留与计算效率之间的平衡，本模块通过对时空数据进行分割、池化与整合操作，提取关键特征并降低计算负担。其主要流程如下：首先，数据划分，将输入的时空数据划分为若干子区块，划分方式可基于空间区域或时间段，从而实现局部特征的分组处理。其次，池化操作，在每个子区块内采用池化策略（如最大池化或平均池化）对特征进行压缩。此过程保留区块中最具代表性的特征值，显著减少数据维度，从而降低后续计算的资源消耗与复杂度。接着，特征融合，对各子区块池化后的输出结果进行融合，形成更高层次的特征表示。这种整合方式能够有效捕捉局部关键特征，有助于保持整体的时空结构信息。最后，多层次处理，模块采用多尺度策略，在不同层次中设置不同的池化尺寸与步长，实现跨尺度特征抽象。该机制有助于在不同粒度上提取信息，提高模型对时空结构的感知能力与泛化能力。

### 2.3 模型训练策略与参数设置

为了确保模型训练的稳定性 and 优化效果，本研究采用自适应矩估计 (adaptive moment estimation, Adam) 优化器进行训练，具体超参数设置为：学习率为 0.000 1，动量系数  $\beta_1$  和  $\beta_2$  分别为 0.9 和 0.999，批量大小设置为 16，损失函数采用交叉熵损失函数，以衡量模型预测与真实标签之间的差异。

表 2 模型性能评估结果

Tab.2 Model performance evaluation results

| 数据集 | 精确率   | 召回率   | F <sub>1</sub> 分数 |
|-----|-------|-------|-------------------|
| 训练集 | 98.0% | 97.5% | 0.98              |
| 验证集 | 97.1% | 97.0% | 0.97              |
| 测试集 | 96.5% | 95.0% | 0.96              |

在训练阶段，模型迭代轮数设定为 100。为抑制过拟合并增强模型的泛化能力，训练阶段引入三项策略：其一，早停机制，若验证集损失在连续 10 轮内无明显下降，则提前终止训练，防止性能退化；其二，学习率调度机制，当验证集损失在连续 5 轮内未下降时，自动将学习率减半，以加快模型收敛速度；其三，批量归一化处理，在每一卷积层后引入批量归一化操作，用于规范特征分布，缓解梯度消失问题，并提升训练过程的稳定性与收敛效率。

## 3 实验结果与分析

### 3.1 模型性能评估结果与分析

鉴于本研究任务为步态识别的二分类问题，且数据集中正负样本数量平衡，选取精确率 (以符号  $P_{re}$  表示)、召回率 (recall, Rec) (以符号  $R_{ec}$  表示) 和  $F_1$  分数 ( $F_1$ -score) (以符号  $F_1$  表示) 作为主要指标<sup>[32]</sup>，全面评估模型的识别性能。其中，精确率衡量模型预测为正类样本中真正例所占的比例，召回率衡量实际正类样本中被正确识别的比例， $F_1$  分数为两者的调和平均值，能够综合反映模型对关键类别的识别能力。上述指标的计算公式分别如式 (4) ~ 式 (6) 所示：

$$P_{re} = \frac{TP}{TP + FP} \times 100\% \quad (4)$$

$$R_{ec} = \frac{TP}{TP + FN} \times 100\% \quad (5)$$

$$F_1 = 2 \times \frac{(P_{re} \times R_{ec})}{(P_{re} + R_{ec})} \quad (6)$$

其中，真阳性 (true positive, TP) 表示正类别中正确分类样本的数量；真阴性 (true negative, TN) 表示负类别中正确分类样本的数量；假阳性 (false positive, FP) 表示正类别中错误分类样本的数量；假阴性 (false negative, FN) 是负类别中错误分类样本的数量。模型性能评估结果如表 2 所示。

表 2 结果表明，本文模型在三组数据集上均展现出较强的步态识别区分能力，并在误诊率与漏诊率控制方面表现优异，具体体现在四个方面：① 高精确率：模型在减少误报方面表现优异，能



够精准区分正常步态与膝外翻步态，有效减少将正常步态误诊为异常的情况，提高临床筛查的准确性。

② 高召回率：模型具有较强的异常步态检出能力，即假阴性较低，能够有效识别大多数膝外翻个体，降低漏诊风险，保障筛查的全面性与敏感性。

③ 高特异性与低假阳性率：高特异性表明，模型在识别正常步态时表现稳定，误报率较低，临床诊断可靠；低假阳性率表明，模型不会频繁误判正常步态，减少了不必要的临床干预。

④ 高  $F_1$  分数：模型不仅具备较强的异常步态识别能力，同时能够有效控制误报率。

综上所述，本文所提出的模型在精确率、召回率与  $F_1$  分数等关键性能指标上均表现优异，体现出较强的分类能力与良好的泛化性能。同时，模型在误诊控制、异常步态识别以及特异性等方面的稳定表现，进一步验证了其在实际临床辅助筛查中的可行性与实用价值，为儿童膝外翻步态的早期识别提供了有效且可靠的技术支撑。

3.2 不同注意力机制与池化策略对模型性能的影响

为验证不同注意力机制与池化策略在步态识别任务中的性能差异，本文设计了对比实验，系统地评估了三种注意力机制与三种池化策略对模型性能的影响。所选注意力机制包括：本研究提出的 TAM、三维挤压激励机制 (three dimensional squeeze-and-excitation, SE-3D) [39] 和卷积块注意力模块 (convolutional block attention module, CBAM) [40]；池化策略包括：本文提出的 SHPM、时序上下文池化 (temporal context pooling, TCP) [41] 和水平金字塔池化 (horizontal pyramid pooling, HPP) [42]。实验结果分别如表 3 和表 4 所示，其中粗体字为本文方法所用机制与策略的结果。

在注意力机制的对比评估中，本研究提出的 TAM 的精确率、召回率与  $F_1$  分数等指标结果均最优，充分证明其在步态特征提取与判别能力方面的有效性。 $F_1$  分数达 0.89，显示出其在时空特征融合与动态信息建模方面的显著优势。TAM 通过同时建模时间、空间与通道维度的注意力权重，实现了对步态关键动作变化 (如足部离地、膝关节动态变化等) 的精准聚焦。相比之下，对比方法 SE-3D 主要侧重于通道间权重分配，CBAM 虽融合了空间与通道注意力机制，但二者均没有建模时间维度，导致其对动态步态特征的捕捉能力存在局限；二者  $F_1$  分数均为 0.84，即整体性能提升幅度相对有限，说明其在捕捉关键步态特征方面仍存在不足。实验结果表明，引入多维度注意力机制，尤其是对时

表 3 注意力机制对比结果

Tab.3 Comparison results of attention mechanisms

| 方法    | 精确率    | 召回率    | $F_1$ 分数 |
|-------|--------|--------|----------|
| TAM   | 89.5 % | 89.0 % | 0.89     |
| SE-3D | 87.1 % | 82.0 % | 0.84     |
| CBAM  | 86.7 % | 81.4 % | 0.84     |

表 4 池化策略对比结果

Tab.4 Comparison results of pooling strategies

| 方法   | 精确率    | 召回率    | $F_1$ 分数 |
|------|--------|--------|----------|
| SHPM | 91.3 % | 90.5 % | 0.91     |
| TCP  | 86.5 % | 81.0 % | 0.84     |
| HPP  | 86.3 % | 80.0 % | 0.83     |

表 5 消融实验对比结果

Tab.5 Comparison results of ablation experiment

| 模型类型       | 精确率    | 召回率    | $F_1$ 分数 |
|------------|--------|--------|----------|
| 本文模型       | 96.5 % | 95.0 % | 0.96     |
| 本文模型移除TAM  | 91.3 % | 90.5 % | 0.91     |
| 本文模型移除SHPM | 89.5 % | 89.0 % | 0.89     |

间维度的建模，是提升步态识别等时序建模任务性能的有效路径。

在池化策略的对比评估中，本研究提出的 SHPM 的三项指标结果也均最优。 $F_1$  分数达 0.91，展现出更强的特征表达与判别能力。SHPM 通过多尺度区域划分与层级聚合机制，保留全局结构的同时强化局部细节，有效提升了模型对下肢步态变化的适应性与鲁棒性。相较而言，TCP 虽引入时序上下文，但空间建模能力不足；HPP 则仅建构水平方向的分层信息，忽略了垂直变异与关键部位的结构表达，整体性能提升有限。结果表明，捕捉步态中，SHPM 在复杂空间模式方面更具优势，是提升模型性能的关键设计。

综上所述，TAM 与 SHPM 分别在时序建模与空间结构表达中发挥关键作用，前者强化模型对关键时空特征的聚焦能力，后者提升其对多尺度空间信息的表达精度。二者的联合设计实现了动态特征感知与静态结构建模的有机结合，显著增强了模型的分类判别能力、稳定性与部署效率。本文实验结果充分验证了多维注意力机制与空间层级池化策略在异常步态识别任务中的协同优势与应用价值。

3.3 消融实验结果与分析

通过消融实验，验证模型组件对性能的影响。实验中依次移除 TAM 和 SHPM，根据每次移除后模型在测试集上的精确率、召回率和  $F_1$  分数的指标值，对模型性能做出相应的评估，实验结果如表 5

表 6 不同模型识别步态的性能比较

Tab.6 Performance comparison of gait recognition using different models

| 指标                | C3D   | 3D ResNet | R(2 + 1)D | Uniformer-B | GaitFormer | 本文模型         |
|-------------------|-------|-----------|-----------|-------------|------------|--------------|
| 精确率               | 85.0% | 88.2%     | 90.5%     | 92.3%       | 89.4%      | <b>96.5%</b> |
| 召回率               | 78.0% | 82.4%     | 87.0%     | 90.1%       | 83.5%      | <b>95.0%</b> |
| F <sub>1</sub> 分数 | 0.81  | 0.85      | 0.89      | 0.91        | 0.86       | <b>0.96</b>  |

所示,其中加粗字为本文模型的性能评估结果。

在消融实验中,移除 TAM 后,模型的时空特征提取能力显著下降,难以有效聚焦于与步态异常相关的关键区域;同时,时间维度上的动态权重分配机制缺失,导致模型在处理复杂时间序列数据时鲁棒性减弱,尤其在识别步态异常的细微时序变化方面性能下降。而移除 SHPM 后,模型对局部空间特征的感知能力进一步削弱,尤其在处理具有复杂空间模式的异常步态(例如步态中的微小偏差或局部异常)时,模型更易产生信息丢失。此外,缺乏分层特征整合机制使得模型难以兼顾局部与全局信息,整体泛化能力和识别精确率进一步降低。

3.4 对比实验结果与分析

为全面评估本文所提出模型在步态识别任务中的性能,选取五个具有代表性的主流模型作为对比基线,它们分别为 Conv3D 网络(Conv3D network, C3D)模型、三维残差网络(three-dimensional residual network, 3D ResNet)模型、残差二维加一维卷积网络(two-dimensional residual plus one-dimensional convolutional network, R(2+1)D)模型、统一时空表示学习网络基础(unified spatiotemporal representation learning network-base, Uniformer-B)模型和基于变换器(transformer)的步态识别网络(transformer-based gait recognition network, GaitFormer)模型。在自建步态数据集上对上述模型进行了系统性测试与比较,旨在验证本文模型在识别精度、召回能力及综合性能等方面的有效性与优越性。实验结果如表 6 所示,其中加粗字为本文模型的性能评估结果。为深入剖析本文模型性能提升的机制,现从以下三个方面展开系统分析。

第一,时空特征建模能力显著增强,是本研究模型的关键优势之一。传统步态识别模型在时空建模方面存在明显局限,例如 C3D 与 3D ResNet 依赖固定的 Conv3D 核,难以有效捕捉跨帧的长程运动模式;R(2 + 1)D 虽采用时空分解卷积策略以缓解计算负担,但受限于 CNN 架构本身,其全局时序建模能力依然不足。尽管 Uniformer-B 和 GaitFormer 在全局建模能力上有所提升,但由于缺乏

CNN 的局部感知能力与平移不变性,其在空间细节的提取与处理方面效率有限。相比之下,本文提出的模型引入多尺度时空卷积结构,融合浅层局部卷积与深层扩张卷积策略,实现了局部与全局时空信息的协同建模。实验结果表明,在跨视角步态识别任务中,该结构显著增强了模型对关键动作模式的捕捉能力,识别精确率较现有主流模型提升,展示出更优的泛化性能与实用价值。

第二,特征选择能力得到进一步优化,有效提升了模型的表达能力与鲁棒性。传统 CNN 模型依赖固定卷积核提取判别特征,缺乏对动态变化区域的自适应关注能力,难以灵活调整对不同时间帧和空间区域的响应强度。而纯 transformer 虽具备长距离建模优势,但在局部建模能力和推理效率方面存在一定限制。为此,本文引入融合时间、空间与通道三维维度的 TAM。其中,时间注意力用于聚焦关键帧,增强对动态变化区域的响应;空间注意力聚焦于判别区域的定位,强化空间结构信息;通道注意力则优化特征通道的权重分配,提升语义维度表达效果。通过 TAM 的多维建模机制,模型在保持高识别精度的同时,在鲁棒性和推理效率方面均有明显提升,展现出优异的实用性能。

第三,计算效率与部署性能实现双重优化,显著增强了模型的实际应用能力。尽管现有主流 transformer 架构在时序建模方面具有优势,但其计算复杂度高、参数量大,难以适配边缘计算等资源受限的应用场景;相比较之下,轻量 CNN 模型尽管资源开销较低,但在准确性和建模能力上存在一定折中。为实现性能与效率的协同优化,本文提出了分层特征融合策略,即在浅层阶段采用轻量卷积以快速提取局部特征,在深层阶段引入稀疏注意力机制以建模长程依赖关系。同时,设计动态计算分配机制,可根据输入特征的复杂性动态调整计算路径与资源配置策略,从而提升模型的灵活性与适应性。实测结果表明,该模型在保证识别精度的基础上,推理速度达 45 帧/s,计算负载大幅降低,能够有效满足实时识别与边缘部署的双重需求。

综上所述,本文提出的步态识别模型在识别精度、鲁棒性与计算效率等多个维度均实现了显著提






图4 步态模型识别可视化

Fig.4 Visualization of gait model recognition

升,展现出优异的综合性能与广阔的应用前景。未来,相关研究可进一步探索模型结构的轻量化与模块化设计,以适配低功耗设备及移动端部署等资源受限场景,推动步态识别技术在临床步态分析与智能康复系统中的深度应用,并提供更加高效、便捷的技术支持。

### 3.5 可视化实验结果与分析

模型可视化在深度学习研究中具有重要作用,能够直观展现模型的特征提取和决策过程,增强其透明性和可解释性。本研究采用 Grad-CAM 方法<sup>[43]</sup>,对步态识别模型进行了可视化处理,结果如图4所示。Grad-CAM 通过反向传播分类梯度,生成反映模型关注区域的热力图,从而揭示其在判别过程中所依赖的关键特征。热力图显示,模型在识别正常步态与膝外翻步态时的高响应区域主要集中于膝部及下肢关节等关键解剖部位,表明模型能够有效聚焦于与临床诊断密切相关的运动解剖区域,所提取的特征与人体运动解剖学相吻合。这一机制增强了模型在临床辅助诊断中的可信度与可解释性。此外,热力图还可为模型优化提供反馈依据,例如通过增强特征多样性以提升模型的泛化能力等。

## 4 结论与展望

本研究构建了一种融合 TAM 与 SHPM 的步态识别模型,并将其应用于儿童膝外翻异常步态的自动识别任务中。该模型在训练集、验证集与测试集上的精确率分别达到 98.0%、97.1% 和 96.5%,在召回率与  $F_1$  分数等指标上也表现出良好的稳定性,验证了其在识别准确性、鲁棒性与泛化能力方面的优越性能。在结构设计上,TAM 通过引入时间、空

间与通道三维注意力机制,增强模型对关键特征的聚焦能力;SHPM 则通过多尺度特征划分与重组,有效整合局部与全局信息,在保障识别精度的同时控制了计算开销。本文采用消融实验与 Grad-CAM 可视化结果进一步验证了关键模块的有效性与模型的可解释性,为步态识别技术在临床辅助诊断中的应用提供了有力支撑。

未来研究将聚焦以下两个方向:一是构建包含结构性解剖参数的多级标签数据集,实现分级识别;二是引入多任务学习框架,将步态类型的分类与关键指标(如步态角度或步幅)的回归任务结合,通过多目标协同优化提升模型的判别能力与泛化性能。

### 重要声明

利益冲突说明:本文全体作者均声明不存在利益冲突。

作者贡献声明:宋校能负责数据采集与前期处理,承担视频数据的标注工作,主导论文的整体框架设计及主要内容的撰写与修改;钱琨参与研究方案设计,并对模型构建方法提供技术指导与建议;后烜负责视频数据的处理、模型的构建与训练,并参与部分内容的撰写;王亦哲参与论文撰写,负责模型性能验证与结果分析工作。

伦理声明:本研究通过江南大学医学伦理委员会的批准(批准编号:JNU2023099011RB04)。

### 参考文献

- 1 World Health Organization. Working for a brighter, healthier future: how WHO improves health and promotes well-being for the world's adolescents. Geneva, Switzerland, World Health Organization, 2024: 1-9.
- 2 陶芳标. 构建面向健康中国2030青少年健康促进体系. 中国学校卫生, 2023, 44(1): 1-5.

- 3 Dop D, Pădureanu V, Pădureanu R, *et al.* Risk factors involved in postural disorders in children and adolescents. *Life*, 2024, 14(11): 1463.
- 4 魏铭, 牛雪松, 吴昊. 体医融合视域下青少年体态异常防治的现实路径. *沈阳体育学院学报*, 2022, 41(4): 57-63.
- 5 Rob C F, Hossain M D J, Kang X S. Management of post-traumatic genu valgus deformity in adolescent by proximal tibial corticotomy with bone lengthening by ilizarov method: a case report. *MOJ Orthop Rheumatol*, 2023, 15(6): 219-223.
- 6 Buchan S, Bennet S, Barry M. Genu valgum in children. *Orthopaedics and Trauma*, 2022, 36(6): 311-316.
- 7 Jamil K, Chew W Y, Bohari N E, *et al.* Knee measurements among children with normal alignment, physiologic and pathologic bowing aged 0-3 years old: a systematic review. *Journal of Pediatric Orthopaedics B*, 2022, 31(2): 105-113.
- 8 Coppa V, Marinelli M, Procaccini R, *et al.* Coronal plane deformity around the knee in the skeletally immature population: a review of principles of evaluation and treatment. *World Journal of Orthopedics*, 2022, 13(5): 427-443.
- 9 Moon S H, Kwon S S, Park M S, *et al.* Change of limb alignment in Korean children and adolescents with idiopathic genu valgum. *Medicine*, 2021, 100(45): e27637.
- 10 Di Gennaro G L, Trisolino G, Stallone S, *et al.* Guided growth technique for epiphysiodesis and hemiepiphysiodesis: safety and performance evaluation. *Children*, 2023, 11(1): 49.
- 11 Sanchis G J B, Nascimento J A S D, Santana R C, *et al.* Biomechanical factors associated with patellofemoral pain in children and adolescents. *Scientific Reports*, 2024, 14(1): 15490.
- 12 Khou S B, Saki F, Tahayori B. Muscle activation in the lower limb muscles in individuals with dynamic knee valgus during single-leg and overhead squats: a meta-analysis study. *BMC Musculoskeletal Disorders*, 2024, 25(1): 652.
- 13 Lee S H, Choi Y, Lee J, *et al.* Valgus arthritic knee responds better to conservative treatment than the varus arthritic knee. *Medicine*, 2023, 59(4): 779.
- 14 顾耀东, 徐昇宁. 智能化儿童青少年体态健康评估预测模型开发——以小学龄儿童青少年膝关节内外翻为例. *上海体育大学学报*, 2025, 49(4): 9-19.
- 15 Ranade A S, Oka G A, Belthur M V, *et al.* An international consensus on evaluation and management of idiopathic genu valgum: a modified delphi survey. *Journal of Pediatric Orthopaedics*, 2025, 45(5): 274-280.
- 16 房依婷, 黄雨琦, 于幸, 等. 双任务范式在帕金森发病早期筛查中的应用进展. *中国疗养医学*, 2023, 32(6): 591-594.
- 17 Kirby J C, Jones H, Johnson B L, *et al.* Genu valgum in pediatric patients presenting with patellofemoral instability. *Journal of Pediatric Orthopaedics*, 2024, 44(3): 168-173.
- 18 Meng D, He S, Wei M, *et al.* Enhanced predicting genu valgum through integrated feature extraction: utilizing ChatGPT with body landmarks. *Biomedical Signal Processing and Control*, 2024, 97: 106676.
- 19 Munusamy V, Senthilkumar S. Emerging trends in gait recognition based on deep learning: a survey. *Peer J Comput Sci*, 2024, 10: e2158.
- 20 Fan C, Hou S, Huang Y, *et al.* Exploring deep models for practical gait recognition. *arXiv preprint*, 2023, arXiv: 2303.03301.
- 21 Franco A, Russo M, Amboni M, *et al.* The role of deep learning and gait analysis in Parkinson's disease: a systematic review. *Sensors*, 2024, 24(18): 5957.
- 22 Aghababa M P, Andrysek J. Exploration and demonstration of explainable machine learning models in prosthetic rehabilitation-based gait analysis. *PloS One*, 2024, 19(4): e0300447.
- 23 Jeswani J, Shinde S, Singh K, *et al.* Innovative approaches in gait analysis for genu valgum using machine learning techniques. *TechRxiv*, 2024, DOI: [10.36227/techrxiv.173194435.53042495/v1](https://doi.org/10.36227/techrxiv.173194435.53042495/v1).
- 24 Bilal M, Jianbiao H, Mushtaq H, *et al.* GaitSTAR: spatial-temporal attention-based feature-reweighting architecture for human gait recognition. *Mathematics*, 2024, 12(16): 2458.
- 25 Cui Y, Kang Y. Multi-modal gait recognition via effective spatial-temporal feature fusion//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Vancouver, Canada: IEEE, 2023: 17949-17957.
- 26 Nie X, Chen X, Jin H, *et al.* Triplet attention transformer for spatiotemporal predictive learning//*Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*. Hawaii: IEEE, 2024: 7036-7045.
- 27 Hu Y, Yang J, Wang Y, *et al.* Multi-modal variable-channel spatial-temporal semantic action recognition network//*International Conference of Pioneering Computer Scientists, Engineers and Educators (ICPCSEE 2024)*. Singapore: Springer Nature Singapore, 2024: 139-153.
- 28 Junaid M I, Prakash A J, Ari S. Human gait recognition using joint spatiotemporal modulation in deep convolutional neural networks. *Journal of Visual Communication and Image Representation*, 2024, 105: 104322.
- 29 Saoud L S, Hussain I. TempoNet: empowering long-term knee joint angle prediction with dynamic temporal attention in exoskeleton control//*Proceedings of the 2023 IEEE-RAS 22nd International Conference on Humanoid Robots (Humanoids)*, Austin, USA: IEEE, 2023: 1-8.
- 30 Ding G, Georgilas I, Plummer A. A deep learning model with a self-attention mechanism for leg joint angle estimation across varied locomotion modes. *Sensors*, 2023, 24(1): 211.
- 31 Yan M, Guo M, Sun J, *et al.* Gait recognition in different terrains with IMUs based on attention mechanism feature fusion method. *Neural Processing Letters*, 2023, 55(8): 10215-10234.
- 32 Wang M, Guo X, Lin B, *et al.* Dygait: exploiting dynamic representations for high-performance gait recognition//*Proceedings of the IEEE/CVF International Conference on Computer Vision*, Paris: IEEE, 2023: 13424-13433.
- 33 Xu H, Zhang C, Wu Z, *et al.* PSGait: gait recognition using parsing skeleton. *arXiv preprint*, 2025, arXiv: 2503.12047.
- 34 Salcedo E. Computer vision-based gait recognition on the edge: a survey on feature representations, models, and architectures. *Journal of Imaging*, 2024, 10(12): 326.
- 35 Rajpurkar P, Chen E, Banerjee O, *et al.* AI in health and medicine. *Nature Medicine*, 2022, 28(1): 31-38.
- 36 Ng S Y. Anonymity. *The Journal of Pediatrics*, 2023, 263: 113664.
- 37 Yan J, Zheng B, Xu H, *et al.* Making pre-trained language models great on tabular prediction. *arXiv preprint*, 2024, arXiv: 2403.01841.
- 38 An Y, Song C. Multiscale dynamic attention and hierarchical spatial aggregation for few-shot object detection. *Applied Sciences*, 2025, 15(3): 1381.
- 39 Hong S B, Kim Y H, Nam S H, *et al.* S3D: squeeze and excitation 3D convolutional neural networks for a fall detection system.

[Mathematics](#), 2022, 10(3): 328.


- 40 Woo S, Park J, Lee J, *et al.* CBAM: convolutional block attention module. arXiv preprint, 2018, arXiv: 1807.06521.
- 41 Gao Z, Wang Q, Zhang B, *et al.* Temporal-attentive covariance pooling networks for video recognition. *Advances in Neural Information Processing Systems*, 2021, 34: 13587-13598.
- 42 Sun Y, Long H, Feng X, *et al.* GaitASMS: gait recognition by adaptive structured spatial representation and multi-scale temporal aggregation. [Neural Computing and Applications](#), 2024, 36(13):

7057-7069.

- 43 Manoharan J, Sivagnanam Y. A novel human action recognition model by Grad-CAM visualization with multi-level feature extraction using global average pooling with sequence modeling by bidirectional gated recurrent units. [International Journal of Computational Intelligence Systems](#), 2025, 18(1): 1-20.

收稿日期: 2025-04-02 修回日期: 2025-08-01

本文编辑: 陈咏竹



(上接第 993 页; *Continued from Page 993*)

- 26 Truong N D, Nguyen A D, Kuhlmann L, *et al.* Convolutional neural networks for seizure prediction using intracranial and scalp electroencephalogram. [Neural Netw](#), 2018, 105: 104-111.
- 27 Ji H, Xu T, Xue T, *et al.* An effective usion model for seizure prediction: GAMRNN. [Front Neurosci](#), 2023, 17: 1246995.
- 28 Duan L, Hou J, Qiao Y, *et al.* Epileptic seizure prediction based on convolutional recurrent neural network with multi-timescale// *Proceedings of the International Conference on Intelligent Science and Big Data Engineering (ICISBDE)*, Nanjing: Nanjing University

& ICISBDE Organizing Committee, 2019: 139-150.

- 29 Lee D, Kim B, Kim T, *et al.* A ResNet-LSTM hybrid model for predicting epileptic seizures using a pretrained model with supervised contrastive learning. [Sci Rep](#), 2024, 14: 1319.
- 30 Zhang J, Zheng S, Chen W, *et al.* A scheme combining feature fusion and hybrid deep learning models for epileptic seizure detection and prediction. [Sci Rep](#), 2024, 14: 16916.

收稿日期: 2025-02-24 修回日期: 2025-09-22

本文编辑: 陈咏竹